

EDA 리포트: KOSPI200 종목의 향후 5거래일 최대 낙폭(MDD_5) 예측 변수 탐색

- 작성일: 2026-09-28
- 범위: 학습 구간 2024-01-02 ~ 2026-06-30 데이터(분석 표본 2024-04-01 ~). 검증 구간(2026-07 ~ 08) 값은 보지 않았다. 건수와 날짜 범위만 확인했다.
- 재현: outputs/notebooks/01_schema.ipynb ~ 07_summary.ipynb (커널 stock_risk, 위에서부터 다시 실행 가능)
- 상세 표: outputs/data_dictionary.md (스키마 결정 사항), outputs/feature_candidates.csv (변수 130개 평가)

0. 요약

- 주 타킷은 mdd_low_clean이다. 정의는 $\min(\text{보정 Low}[t+1..t+5]) / \text{Close}[t] - 1$ 이며 연속값이다. 분석 표본 107,172쌍에서 중앙값 -3.3%, 10% 분위 -10.0%, 1% 분위 -20.5%다.
- 가장 큰 데이터 문제는 NXT 출범(2025-03-04) 이후 일봉에 섞인 비정상 저가-고가다. 이 때문에 MDD_5 ≤ -20% 표본의 20%가 오염된다. 같은 날 정보로 보정했지만, 근본 해결책은 KRX 단독 시세이며 데이터 제공처에 확인 중이다.
- 종목 간 위험 차이는 과거 변동성이 가장 잘 설명한다. gk_5는 IC -0.33, IC IR -2.16이다. 여기에 가격 위치(60일 저점 대비 상승폭), 하방 특성(왜도, 과거 낙폭), 베타, 신용잔고율, 연기금 순매수가 변동성을 통제한 뒤에도 설명력을 더한다.
- 시장 전체의 위험 수준(날짜 공통 요인)은 분산의 39%를 차지하지만, 이를 안정적으로 예측하는 시장 변수는 찾지 못했다. 가장 나은 KOSPI 20일 수익률도 $\rho = -0.26$ 이고, 관계는 주로 2026년 상반기에서 나온다.
- 학습 구간 끝(2026년 상반기)은 이례적인 고변동 국면이다. ≤ -10% 비율이 평소 4~10%에서 21%로 올랐다. 이 국면 직후인 검증 구간의 성능은 크게 흔들릴 수 있다.

1. 데이터와 범위

항목	내용
원천	MySQL(읽기 전용). 종목 일봉, 구성종목 월별 스냅샷, 수급(투자자별·기관 세부 프로그램·공매도·신용·대차), 지수·금리
기간	모든 테이블이 2024-01-02부터다. 위밍업은 2024-01-02 ~ 03-29(61거래일), 분석 표본은 2024-04-01 ~ 2026-06-30(545거래일)이다
유니버스	각 거래일에 그날 이하 가장 최근 월초 스냅샷의 KOSPI200 구성종목. 가격 데이터가 없는 3종목은 제외한다. 108,172쌍, 225종목
타킷 계산 가능	107,172쌍. 학습 구간 마지막 5거래일(2026-06-24 ~ 30, 1,000쌍)은 엠바고라 비워 둔다
변수 제약	롤링 원도우 최대 60거래일(t일 이전 필요 거래일 ≤ 61). 예측 시점은 t+1일 장 시작 전이며, t일 장 마감 후 공표 데이터는 lag 없이 쓴다

2. 데이터 문제

#	문제	수치 근거
1	NXT 이후 비정상 포리	증가는 ±5% 이내인데 저가-고가가 15% 이상 튜 행이 1만 행당 2.5건에서 26.5건으로 늘었다(저가 91건, 고가 120건). 저가 스파이크 깊이 중앙값은 -27.8%이고 64%는 시가 = 저가다. 예: 삼성전자 2026-02-06 저가 -30.7%, 증가 -0.1%
2	NXT 이후 증가가 KRX 상한가 초과	상한가 증가 중 제한가를 넘는 비율이 NXT 이전 0/17, 이후 17/51이다. 일봉이 KRX+NXT 통합 시세(08:00 ~ 20:00)일 가능성이 높다(가설)
3	위밍업 데이터 없음	모든 테이블이 2024-01-02에 시작한다
4	구성종목 3개의 데이터 전무 (003410, 010620, 042670)	수집 로그 404 stock-not-found. 학습 구간 1,072쌍(0.88%)이다. 상장폐지·합병 종목으로 추정
5	구성종목 이력이 월 1회 스냅샷	정기변경 효력일(추정)보다 11 ~ 12거래일 늦게 반영된다. 틀릴 수 있는 쌍은 592개(0.55%)
6	거래정지	거래량 0이 440행(12종목)이고, 437행은 OHLC가 전일 증가로 고정돼 있다. 분석 표본에서 105쌍이다. 구간에 정지일이 있는 타킷 147쌍 중 85쌍은 증가 기준 MDD가 정확히 0이다
7	공매도 체제 변화	전면 금지 기간(~2025-03-28) 공매도 비중 중앙값 0.24%, 재개 후 6.3%. 금지 기간 행 누락 2.7%
8	수급 데이터 사후 갱신	대차 2024-01 ~ 07 전체(32,129행)가 2024-08-08에 일괄 재갱신됐다. 투자자별 693행, 신용 229행이 t+1일 09:00 이후 갱신됐다
9	수정주가는 수집 시점 기준 소급 조정	26종목에서 호가 단위와 맞지 않는 과거 가격이 있다. 조정 경계일에 ±30%를 넘는 점프는 없다
10	기타	KOSPI200 지수 없음(KOSPI로 대체), 발행주식수는 현재값뿐, stock_warnings -분봉 0행, 거래대금 컬럼 없음(증가×거래량 근사), CFD 잔고 결측 16%, 신용·대차에 휴장일(12-31) 행 455행

문제가 없던 항목: 중복, NULL, 가격 0 이하, OHLC 논리 위반, 종목별 중간 결측 거래일, 수급 항등식(순매수 = 매수 - 매도, 기관 세부 합 = 기관 순매수)은 모두 0건이다.




그림 1. 월별 비정상 꼬리(스파이크) 건수. NXT 출범 이후 급증

3. 타깃 정의 의견

정의	중앙값	10% 분위	1% 분위	$\leq -10\%$	양수 비율	비고
mdd_low 저가 원본	-3.3%	-10.1%	-21.8%	10.3%	4.8%	계획서 기본 정의
mdd_low_clean 저가 보정	-3.3%	-10.0%	-20.5%	10.0%	4.8%	주 타깃
mdd_close 증가	-2.0%	-8.3%	-17.6%	6.5%	23.4%	장중 저점을 놓친다
mdd_path 고점 대비	-3.3%	-9.4%	-18.7%	8.6%	0%	t일 증가 대비 손실과 의미가 다르다

의견과 결정

- **mdd_low_clean**을 주 타깃으로 한다.
 - 원본과의 Spearman은 0.993으로 분포 중심은 거의 같다.
 - 꼬리에서만 차이가 난다. $\leq -20\%$ 표본 중 20.3%, $\leq -15\%$ 표본 중 9.1%는 구간 최저가가 비정상 저가에서 나왔다. 이 표본들의 증가 기준 MDD 중앙값은 -1.7%에 불과하다.
- 연속값(회귀)으로 유지하고, 양수 값도 그대로 쓴다. 계획서의 "0 이하 값"은 성립하지 않는다.
- 증가 기준과 고점 대비 정의는 보조 확인용이다. 증가 기준 타깃에서도 변수 IC의 부호는 모두 같았고, 크기는 30 ~ 40% 작았다.

타깃의 성질

- 시장 공통 요인이 크다. 날짜 평균이 분산의 39%를 설명한다.
- 국면에 따라 달라진다. $\leq -10\%$ 비율이 반기별로 2024H1 4.4%, 2024H2 10.3%, 2025H1 6.8%, 2025H2 5.4%, **2026H1 20.9%**다. KOSPI -3% 이하 급락일 26일 중 16일이 2026년 2 ~ 6월에 몰려 있다.
- 급락일과의 관계: 급락일이 타깃 구간 안에 들어간 표본은 평균 MDD_5가 -9%로 전체 평균(-4.5%)의 두 배다. 급락 다음 날부터는 평균 수준으로 돌아온다(급락 후 위험이 지속되지 않는다).
- 업종 차이가 유의하다(검정하지 않는 표본 Kruskal-Wallis $p \approx 5e-81$). 같은 날 평균 대비로 비철금속 -1.6%p, 이차전지 -1.4%p, 전기장비 -1.3%p이고, 식품 +1.0%p, 소매 +0.8%p다.
- 자기상관: 오늘 알 수 있는 과거 실현 낙폭이 미래 낙폭과 이어진다. 과거 5일 MDD는 t-5일의 타깃과 같고, IC 0.105(IR 0.67)다.




그림 2. 네 가지 MDD_5 정의의 누적분포와 왼쪽 꼬리




그림 3. 월별 MDD_5 분위. 2026년 상반기 고변동 국면




그림 4. KOSPI 급락일 전후 평균 MDD_5

4. 추천 변수 Top 20

평가 방법(Step 5):

- 날짜별 횡단면 Spearman IC로 평가했다.
- 겹치는 타깃 구간 때문에 유의성은 5거래일 간격의 겹치지 않는 108일 표본의 t값으로 판단했다.
- 전·후반 경계는 2025-05-15다.
- 등급 기준: '강력 추천'은 묶음 대표이고 $|IC| \geq 0.5$, $|t| \geq 4$, 월별 부호 일치 $\geq 80\%$, 전·후반 부호가 같은 변수다.
- 부호: $IC < 0$ 은 값이 클수록 더 크게 빠진다(위험)는 뜻이다.

순위	변수	계열	방향	평균 IC	IC IR	t (비중첩)	변동성 통제 IR	전반 / 후반 IC	관계 모양
1	gk_5	변동성	클수록 위험	-0.329	-2.16	-21.7	-1.70	-0.332 / -0.326	단조
2	range_1	캔들	클수록 위험	-0.283	-1.99	-20.7	-1.32	-0.275 / -0.291	단조
3	idio_vol_60	시장 대비	클수록 위험	-0.312	-1.78	-17.9	-1.12	-0.321 / -0.303	단조
4	vol_5	변동성	클수록 위험	-0.261	-1.66	-17.3	-0.85	-0.256 / -0.265	단조
5	dist_low_60	가격 위치	클수록 위험	-0.260	-1.60	-16.1	-0.83	-0.237 / -0.283	단조
6	min_intra_drop_20	하방 특성	클수록 안전	0.237	1.40	14.1	0.14	0.242 / 0.233	단조
7	ind_vol_20	업종	클수록 위험	-0.234	-1.36	-13.7	-0.45	-0.246 / -0.222	단조
8	lend_days_20	공매도·대차	클수록 안전	0.175	1.15	10.8	0.17	0.170 / 0.181	단조
9	skew_60	하방 특성	클수록 위험	-0.106	-1.13	-10.1	-0.45	-0.115 / -0.097	단조
10	past_mdd_60	하방 특성	클수록 안전	0.170	0.92	9.7	0.34	0.206 / 0.135	단조
11	beta_60	시장 대비	클수록 위험	-0.202	-0.89	-9.5	-0.29	-0.212 / -0.191	단조
12	margin_rate	신용	클수록 위험	-0.152	-0.84	-7.6	-0.30	-0.169 / -0.135	단조
13	downside_ratio_20	하방 특성	클수록 안전	0.123	0.79	8.5	0.37	0.092 / 0.155	단조
14	short_share_20	공매도·대차	클수록 안전	0.102	0.74	6.5	0.12	0.068 / 0.135	단조
15	pension_net_20	수급	클수록 위험	-0.087	-0.74	-8.3	-0.37	-0.053 / -0.120	비단조·약함
16	skew_20	하방 특성	클수록 위험	-0.077	-0.73	-6.8	-0.27	-0.084 / -0.071	단조
17	pension_net_5	수급	클수록 위험	-0.079	-0.68	-7.7	-0.47	-0.047 / -0.112	역U자
18	past_mdd_5	하방 특성	클수록 안전	0.105	0.67	7.3	0.20	0.114 / 0.097	단조
19	days_since_high_60	가격 위치	클수록 안전	0.101	0.66	6.8	0.17	0.064 / 0.137	단조
20	pos_20	가격 위치	클수록 위험	-0.105	-0.65	-7.2	-0.61	-0.073 / -0.138	단조

강력 추천 중 Top 20 밖의 변수: log_value_20, vol_ratio_20_60 (변동성 통제 IR 0.60으로 새로운 정보가 많다), indiv_net_20, foreign_hold, prog_nonarb_net_20. 계산식은 feature_candidates.csv에 있다.

- 해석
- **변동성이 핵심이다.**
 - 1 ~ 4위와 7위는 모두 변동성 계열이다. 이들끼리 횡단면 상관이 0.68 ~ 0.71이라, 모델에는 1 ~ 2개만 넣는 것을 권한다. 고가저가 기반 gk_5 나 range_1 하나에, 시장 요인을 뺀 idio_vol_60을 더하는 조합이다.
 - 저가 기준 타깃에는 장중 변동폭이 들어 있어서, 고가저가 기반 변수의 IC가 어느 정도 부풀려져 있다. 종가 기준 타깃에서 gk_5의 IC는 -0.20이다.
 - **변동성을 통제한 뒤에도 남는 정보(변동성 통제 $|IR| \geq 0.3$):**
 - 가격 위치: dist_low_60, pos_20. 최근 많이 오른 종목이 더 빠진다.
 - 왜도: skew_60. 수익률이 위로 튀던 종목이 위험하다.
 - 과거 낙폭: past_mdd_60, downside_ratio_20
 - 연기금·기관 순매수: pension_net_5/20
 - 변동성 변화: vol_ratio_20_60
 - **변동성의 대리변수일 가능성이 큰 것:**
 - lend_days_20 (IR 1.15 → 통제 후 0.17), short_share_20 (0.74 → 0.12), min_intra_drop_20 (1.40 → 0.14)
 - 대차·공매도가 많은 종목은 변동성이 낮은 대형주라서 안전하게 보이는 것으로 해석된다.
 - **U자 관계:** 수익률·모멘텀 계열(ret_5/20/60, ma_gap_*)은 '검토' 등급이다. 많이 오른 종목과 많이 내린 종목이 모두 위험하다. 선형 모델에 넣으려면 절댓값이나 제곱항이 필요하다.

- 시장 변수(날짜 공통)
- **강력 추천은 없다.** 겹치지 않는 표본이 108일뿐이라 근거가 약하다.
 - 검토 등급 5개: mkt_ret_20 (p -0.26, p 0.006), cs_dispersion_1 (-0.24), mkt_ret_60 (-0.24), mkt_institution_net_20 (-0.19), mkt_ma_gap_20 (-0.16). 시장이 많이 오른 뒤에 낙폭이 크다는 방향인데, 후반부(2026년 상반기)가 주도한다.
 - **시장 변동성은 평균 낙폭을 예측하지 못했다.** mkt_vol_20의 전반 ρ 는 +0.25, 후반은 -0.28이다.

- 눈에 띄게 약한 변수
- 외국인 순매수 (IR -0.16 ~ -0.28), 금융투자 순매수, 차익 프로그램 매매, 신용·대차 잔고 **변화율** (IR |0.04 ~ 0.16|), 척도, 꼬리 비율(1일), CFD 잔고는 설명력이 없다.

- 세 관점 비교
- 폴링 상관과 횡단면 IC의 부호가 다른 종목 변수는 5개다.
 - excess_ret_20: 횡단면 -0.12, 날짜 평균끼리는 +0.32라 폴링하면 상쇄된다.
 - short_share_*: 공매도 금지·재개 국면에서 수준이 달라 폴링 관계가 사라진다.
 - 폴링 상관 하나로 변수를 고르면 이런 변수를 놓치거나 잘못 해석하게 된다.




그림 5. Top 20 변수의 IC IR과 변동성 통제 후 IC IR




그림 6. 분위별 초과 MDD_5 (|IC IR| 상위 12개)




그림 7. 전·후반 IC 비교




그림 8. 시장 변수와 날짜별 평균 MDD_5의 시계열 상관

5. 누수 위험 요소

위험	내용	대응
타킷 함수	src/target.py 는 미래 가격을 쓴다	타킷 전용. 변수 코드에서 import하지 않는다(보정 함수 clean_low 는 같은 날 값만 쓰므로 변수에 써도 된다)
현재값 컬럼	stocks.shares_outstanding, stocks.status 는 수집 시점 값이다	쓰지 않는다. 회전율과 시가총액 변수를 만들지 않은 이유다
업종	stocks.industry 는 현재값이다	업종은 거의 바뀌지 않으므로 정적 속성으로 쓴다(가정)
소급 조정 가격	수정주가가 2026-09 기준으로 조정돼 가격 수준에 미래의 기업 이벤트가 반영돼 있다	비율 변수만 쓴다. log_value_20 (거래대금 수준)은 영향이 작지만 주의가 필요하다
수급 공표 시점	t일 장 마감 후 공표분을 t일 변수로 쓴다(t+1일 장 시작 전 예측이라는 전제)	원천 갱신 시각이 t+1일 09:00 이후인 행에 late_update_20 플래그를 단다. 프로그램 매매와 기관 세부 테이블은 갱신 시각이 없어 확인할 수 없다
사후 재갱신	대차 2024-01 ~ 07 전체가 2024-08-08에 재갱신됐다	대차 변수는 2024-08 이후 표본으로 확인했고, 결론이 같았다
구성종목 소급 수집	스냅샷 34개가 모두 2026-09-16에 한 번에 수집됐다	편입-편출 시점은 공개 규칙과 대체로 맞는다. 월 단위 지연은 플레그로 남긴다
엠바고	학습 구간 마지막 5거래일의 타킷 구간이 검증 구간과 겹친다	타킷을 비워 두었고, 학습에서 제외한다
전체 기간 정규화	없음	롤링과 날짜별 순위만 썼다
검증	데이터 절단 테스트: 2025-06-30 이후를 지우고 다시 계산했을 때 변수 226개 x 71,616행이 전체 계산과 완전히 같았다	05_features.ipynb 2절

6. 모델링 시 주의점

- 시장 요인과 종목 요인을 나눠 평가한다. 분산의 39%가 날짜 공통이다.
 - 횡단면 성능은 날짜별 IC로, 시장 수준 예측은 날짜 평균 MDD의 오차로 따로 본다.
 - 종목 변수만으로는 "오늘 시장 전체가 얼마나 빠질지"를 맞추기 어렵다.
- 국면 변화에 대비한다.
 - 2026년 상반기는 ≤ -10% 비율이 21%로 평소의 2 ~ 5배다.
 - 검증 구간이 이 국면 직후라서, 학습 구간 평균 수준을 그대로 예측하면 크게 틀릴 수 있다.
 - 시간 가중이나 롤링 재학습, 시장 수준 보정을 검토한다.
- 겹치는 타킷을 고려한다.
 - 인접 표본은 타킷 구간을 4일 공유한다.
 - 교차검증은 날짜 블록 단위로 나누고, 블록 사이에 5거래일 간격을 둔다(purge/embargo).
 - 유익성은 겹치지 않는 표본으로 본다.
- 변동성 계열의 중복을 정리한다. 대표 1 ~ 2개만 쓰거나 규제(regularization)를 건다.
- 비선형성을 처리한다. 수익률-모멘텀은 U자, 연금금-프로그램 순매수 일부는 역U자다. 트리 모델이나 |값|-제곱항을 쓴다.
- 꼬리 위험을 따로 점검한다. 타킷 분포의 왼쪽 꼬리가 두껍다(왜도 -1.9, 초과 첨도 5.5). 평균 오차 외에 하위 10% 구간의 순위 성능과 보정을 따로 본다.
- 데이터가 바뀌면 다시 돌린다. KRX 단독 시세를 받으면 다음을 다시 계산한다.
 - 타킷(mdd_low)과 고가저가 기반 변수(clean=False)
 - Step 5 평가
- 공매도 변수는 체제 구분이 필요하다. 2025-03-31 이전 값은 금지 기간이라 성격이 다르다. 학습 기간에 따라 가중을 달리하거나, 재개 이후만 쓴다.
- 거래저지 표본을 처리한다. 구간에 정지일이 있는 타킷은 낙폭이 0으로 눌린다. 학습에서 빼거나 가중을 낮추는 것을 검토한다(147쌍).

7. 한계와 남은 작업

- **KRX 단독 시세 확보 후 재실행**(데이터 제공처 확인 중). 받을 때 폐지.합병 3종목, KOSPI200 지수, 구성종목 변경 효력일, 거래정지 이력을 함께 받으면 2절의 1-2-4-5-10번이 해결된다.
- 추천 등급 기준은 분석자가 정한 경험적 기준이다. 06_relation.ipynb 7절에서 조정할 수 있다.
- 업종 변수는 현재 업종 분류를 과거에도 쓴 것이다.
- 시장 변수 평가는 108개 비중첩 날짜에 기반하므로 통계적 검정력이 낮다.

부록: 산출물

파일	내용
outputs/data_dictionary.md	스키마, 사용 가능 여부, 공표 시차, 결정 사항
outputs/feature_candidates.csv	변수 130개: 계열, 계산식, 필요 과거 기간, 평균 IC, IC IR, 안정성, 추천 등급, 비교
outputs/notebooks/01_schema ~ 07_summary.ipynb	Step 0 ~ 6
outputs/figures/	그림 11개
src/	db.py, data.py, universe.py, target.py, features.py, evaluate.py, plotting.py
data/cache/	Parquet 캐시(유니버스, 타겟, 변수, 평가 결과)