

EDA 리포트: KOSPI200 종목의 향후 5거래일 최대 낙폭(MDD_5) 예측 변수 탐색 (v2)

- 작성일: 2026-09-28 (v2: KRX 정규장 일봉으로 재분석. v1은 `outputs/archive_v1/`)
- 범위: 학습 구간 2024-01-02 ~ 2026-06-30 데이터(분석 표본 2024-04-01 ~). 검증 구간(2026-07 ~ 08) 값은 보지 않았다. 건수와 날짜 범위만 확인했다.
- 재현: `outputs/notebooks/01_schema.ipynb` ~ `07_summary.ipynb`, `03b_krx_validation.ipynb`(커널 `stock_risk`, 위에서부터 다시 실행 가능)
- 상세 표: `outputs/data_dictionary.md` (스키마·결정 사항), `outputs/feature_candidates.csv` (변수 133개 평가)

0. 요약

- 가격 데이터를 KRX 정규장 일봉으로 바꿨다. 기존 DB 일봉이 NXT 출범(2025-03-04) 이후 KRX+NXT 통합 시세였다는 것을 확인했다. KRX 일봉에서는 비정상 저가가 90건에서 2건으로 줄었다. 폐지·합병 3종목도 들어와 생존 편향이 해소됐다.
- 주 타킷은 `mdd_low` 다. 정의는 $\min(\text{Low}[t+1..t+5]) / \text{Close}[t] - 1$ (계획서 기본 정의, 연속값)이다. 사용 표본 107,880쌍에서 중앙값 -3.2%, 10% 분위 -9.8%, 1% 분위 -20.1%다.
- 종목 간 위험 차이는 과거 변동성이 가장 잘 설명한다(`gk_5` IC -0.33, IC IR -2.07).
 - 변동성을 통제한 뒤에도 설명력을 더하는 변수: 가격 위치(60일 저점 대비 상승폭), 왜도, 과거 낙폭, 회전율(v2 신규), 베타, 신용잔고율, 연기금 순매수
- v1과 결론이 거의 같다. 변수별 IC IR 상관이 0.996이고, v1의 강력 추천 25개 중 23개가 유지됐다. 데이터 교체로 결론이 흔들리지 않았다.
- 시장 전체의 위험 수준(날짜 공통 요인, 분산의 40%)을 안정적으로 예측하는 시장 변수는 찾지 못했다.
- 학습 구간 끝(2026년 상반기)은 실제 충격 국면이다. 미국·이란 전쟁 충격으로 2026-03-04 KOSPI가 -12.06%(역대 최대)를 기록했다. 이 기간 $\leq -10\%$ 비율은 19.5%로 평소의 2 ~ 4배다. 검증 구간(2026-07 ~ 08)은 이 국면 직후다.

1. 데이터와 범위

항목	내용
가격	KRX 정규장 일봉(<code>krx_daily_candles</code>): 수정주가 OHLC, 거래량, 거래대금, 원주가, 수정계수, 날짜별 상장주식수, 거래정지 플래그. 232종목, 660거래일
기타 원천	MySQL(읽기 전용): 구성종목 월별 스냅샷, 수급(투자자별·기관 세부·프로그램·공매도·신용·대차), 지수·금리
기간	모든 테이블이 2024-01-02부터다. 위밍업은 2024-01-02 ~ 03-29(61거래일), 분석 표본은 2024-04-01 ~ 2026-06-30(545거래일)이다
유니버스	각 거래일에 그날 이하 가장 최근 월초 스냅샷의 KOSPI200 구성종목. 109,061쌍, 228종목(v1보다 889쌍 많다)
사용 표본	타킷이 있는 108,061쌍에서 거래정지 관련 181쌍(1일 정지, 또는 t+1 ~ t+5에 정지일 포함)을 빼고 107,880쌍. 학습 구간 마지막 5거래일(1,000쌍)은 엠바고라 비워 둔다
변수 제약	롤링 윈도우 최대 60거래일(t일 이전 필요 거래일 ≤ 61). 예측 시점은 t+1일 장 시작 전이며, t일 장 마감 후 공표 데이터는 lag 없이 쓴다

2. 데이터 문제

해결된 문제 (v2)

문제 (v1)	해결
NXT 이후 비정상 꼬리: 1만 행당 2.5건에서 26.5건으로 증가 (저가 91건, 고가 120건). MDD_5 ≤ -20% 표본의 20%가 오염	KRX 정규장 일봉으로 교체해 NXT 이후 저가 스파이크가 90건에서 2건으로, 고가가 105건에서 16건으로 줄었다(NXT 이전 수준). 보정이 필요 없어졌다
NXT 이후 증가가 KRX 상한가를 넘는 경우(17/51)	원인 확인: 기존 일봉은 KRX+NXT 통합 시세였다. NXT 이후 거래량이 KRX보다 중앙값 1.31배 많다
폐지·합병 3종목(003410, 010620, 042670)의 가격 전무 (생존 편향)	KRX 일봉에 마지막 거래일까지 들어왔다. 편출 30건 모두 편출 뒤 5거래일 가격이 있다
거래대금 컬럼 없음, 발행주식수가 현재값뿐	KRX 일봉에 실제 거래대금과 날짜별 상장주식수가 있다. 회전율·시가총액 변수를 추가했다
거래정지를 거래량 0으로 추정	KRX halted 플래그를 쓴다(학습 구간 482행). 정지 관련 181쌍을 표본에서 뺀다

남은 문제

#	문제	수치 근거	처리
1	수급 데이터의 기준이 섞여 있다	투자자별 매수 합 / KRX 거래량이 NXT 이후 1.347(이전 0.999)이다. 투자자별·기관 세부 매매는 KRX+NXT 통합 기준이다. 공매도는 KRX 기준이다(공매도 비율 컬럼 = 공매도 ÷ KRX 거래량, 차이 0)	분모를 기준에 맞췄다: 투자자별·기관·신용·대차는 통합 거래량(기존 일봉), 공매도·프로그램 매매는 KRX 거래량
2	폐지·합병 3종목의 수급 데이터가 없다	수급 변수 결측 0.9%	결측으로 둔다
3	워밍업 데이터 없음	모든 테이블이 2024-01-02에 시작한다	윈도우 60일 상한, 표본은 2024-04-01부터. 120일·52주 변수는 만들지 않았다
4	구성종목 이력이 월 1회 스냅샷	정기변경 효력일(추정)보다 11 ~ 12거래일 늦게 반영된다. 틀릴 수 있는 쌍은 615개(0.56%)	그대로 쓰고 rebal_gap_day 플래그를 단다
5	공매도 체제 변화	전면 금지 기간(~2025-03-28)과 재개 이후에 공매도 비중 수준이 다르다	누락은 0으로 채웠다. 재개 이후만으로도 확인했다
6	수급 데이터 사후 갱신	대차 2024-01 ~ 07 전체가 2024-08-08에 일괄 재갱신됐다. 투자자별 693행, 신용 229행이 t+1일 09:00 이후 갱신됐다	late_update_20 플래그. 이 행을 빼도 결론은 같았다
7	시간외 거래량 포함 여부	KRX 거래량·거래대금에 시간외 거래가 섞였는지 API로 구분할 수 없다(가격은 정규장 값)	NXT 이전 구간에서 투자자별 합계와 일치하므로 수급과 포함 범위는 같다. 거래량 변수에만 영향이 있다
8	기타	KOSPI200 지수 없음(KOSPI로 대체. KOSPI 값은 뉴스로 확인한 실제 종가와 일치), stock_warnings 분봉 0행, CFD 잔고 결측 17%, 신용·대차에 휴장일(12-31) 행	5절 누수 위험 참고

문제가 없던 항목(KRX 일봉): 중복, NULL, 가격 0 이하, OHLC 논리 위반은 모두 0건이다. 수정 후 하루 ±30.5%를 넘는 수익률도 0건이다. NXT 이전 구간은 기존 일봉과 최대 0.035% 차이로 같다.




그림 1. 월별 저가 스파이크 건수: 기존 DB 일봉(KRX+NXT 통합) vs KRX 정규장 일봉

3. 타깃 정의 의견

정의	중앙값	10% 분위	1% 분위	$\leq -10\%$	양수 비율	비고
mdd_low 저가 (KRX)	-3.2%	-9.8%	-20.1%	9.5%	6.7%	주 타깃
mdd_close 증가	-2.0%	-8.3%	-18.1%	6.6%	23.4%	장중 저점을 놓친다
mdd_path 고점 대비	-3.3%	-9.4%	-19.1%	8.5%	0%	t일 증가 대비 손실과 의미가 다르다
v1 주 타깃(기존 일봉, 보정 저가)	-3.3%	-10.0%	-20.5%	9.9%	4.8%	비교용

의견과 결정

- **mdd_low (KRX 정규장 저가)**를 주 타깃으로 한다. 계획서 기본 정의 그대로이고, 보정이 필요 없어졌다.
- **v1과 비교**
 - 같은 쌍에서 Spearman 0.974다. NXT 이전에는 사실상 같다(|차이| > 1%p인 쌍 0.01%).
 - NXT 이후에는 15.8%의 쌍이 1%p 넘게 다르다. 정규장만 쓰면 장전·장후 거래가 빠져서 저가가 덜 낮게 잡힌다 (차이 중앙값 +0.1%p).
- **연속값(회귀)**으로 유지하고, 양수 값도 그대로 쓴다.
- 증가 기준과 고점 대비 정의는 보조 확인용이다. 증가 기준 타깃에서도 변수 IC의 부호는 같았고, 크기는 30 ~ 40% 작았다.

타깃의 성질

- **시장 공통 요인이 크다.** 날짜 평균이 분산의 40%를 설명한다.
- **국면에 따라 달라진다.** $\leq -10\%$ 비율이 반기별로 2024H1 4.3%, 2024H2 10.3%, 2025H1 6.4%, 2025H2 4.8%, **2026H1 19.5%**다. KOSPI -3% 이하 급락일 26일 중 16일이 2026년 2 ~ 6월에 몰려 있다.
- **2026년 상반기의 급락은 실제 사건이다.** 미국·이스라엘의 이란 공습과 전쟁 장기화 우려가 원인이었다. 2026-03-03 -7.24%, 03-04 -12.06%(서킷브레이커), 03-31 -4.26%로, DB 값과 뉴스 보도가 일치한다.
- **급락일과의 관계:** 급락일이 타깃 구간에 들어간 표본은 평균 MDD_5가 약 -9%로 전체 평균(-4.3%)의 두 배다. 급락 다음 날부터는 평균 수준으로 돌아온다.
- **업종 차이가 유의하다**(겹치지 않는 표본 Kruskal-Wallis $p \approx 3e-74$). 같은 날 평균 대비로 비철금속 -1.5%p, 이차전지 -1.3%p, 전기장비 -1.2%p이고, 식품 +1.0%p, 소매 +0.9%p다.
- **자기상관:** 과거 20일 변동성 IC -0.31(IR -1.72), 과거 20일 MDD 0.15, 과거 5일 MDD 0.10이다. 겹치지 않는 표본에서도 모두 $|t| > 6$ 이다.




그림 2. 네 가지 MDD_5 정의의 누적분포와 왼쪽 꼬리




그림 3. 월별 MDD_5 분위. 2026년 상반기 고변동 국면




그림 4. KOSPI 급락일 전후 평균 MDD_5

4. 추천 변수 Top 20

평가 방법(Step 5):

- 날짜별 횡단면 Spearman IC로 평가했다.
- 유의성은 5거래일 간격의 겹치지 않는 108일 표본의 t값으로 판단했다.
- 전·후반 경계는 2025-05-15다.
- '강력 추천'은 묶음 대표이고 $|IC| \geq 0.5$, $|t| \geq 4$, 월별 부호 일치 $\geq 80\%$, 전·후반 부호가 같은 변수다.
- 부호: $IC < 0$ 은 값이 클수록 더 크게 빠진다(위험)는 뜻이다.

순위	변수	계열	방향	평균 IC	IC IR	t (비중첩)	변동성 통제 IR	전반 / 후반 IC	v1 순위
1	gk_5	변동성	클수록 위험	-0.326	-2.07	-21.2	-1.63	-0.332 / -0.320	1
2	range_1	캔들	클수록 위험	-0.273	-1.92	-20.2	-1.23	-0.272 / -0.273	2
3	vol_5	변동성	클수록 위험	-0.244	-1.62	-17.4	-0.76	-0.250 / -0.237	4
4	dist_low_60	가격 위치	클수록 위험	-0.254	-1.57	-15.5	-0.82	-0.237 / -0.270	5
5	ind_vol_20	업종	클수록 위험	-0.227	-1.35	-13.6	-0.44	-0.243 / -0.211	7
6	min_intra_drop_20	하방 특성	클수록 안전	0.232	1.33	13.7	0.12	0.244 / 0.221	6
7	skew_60	하방 특성	클수록 위험	-0.118	-1.29	-12.1	-0.57	-0.116 / -0.121	9
8	turnover_20	거래·유동성	클수록 위험	-0.216	-1.24	-11.2	-0.39	-0.230 / -0.202	신규
9	n_down3_60	하방 특성	클수록 위험	-0.254	-1.24	-12.8	-0.50	-0.287 / -0.220	검토
10	lend_days_20	공매도·대차	클수록 안전	0.170	1.12	10.3	0.22	0.169 / 0.170	8
11	past_mdd_60	하방 특성	클수록 안전	0.167	0.89	9.3	0.34	0.203 / 0.131	10
12	skew_20	하방 특성	클수록 위험	-0.084	-0.86	-8.3	-0.31	-0.083 / -0.085	16
13	margin_rate	신용	클수록 위험	-0.154	-0.85	-7.9	-0.36	-0.167 / -0.141	12
14	beta_60	시장 대비	클수록 위험	-0.193	-0.84	-9.1	-0.29	-0.211 / -0.174	11
15	downside_ratio_20	하방 특성	클수록 안전	0.121	0.80	8.4	0.36	0.094 / 0.148	13
16	pension_net_20	수급	클수록 위험	-0.082	-0.71	-7.8	-0.35	-0.052 / -0.112	15
17	short_share_20	공매도·대차	클수록 안전	0.080	0.64	5.3	0.07	0.061 / 0.099	14
18	pos_20	가격 위치	클수록 위험	-0.104	-0.64	-7.1	-0.60	-0.076 / -0.132	20
19	days_since_high_60	가격 위치	클수록 안전	0.095	0.63	6.4	0.16	0.066 / 0.123	19
20	pension_net_5	수급	클수록 위험	-0.072	-0.63	-6.8	-0.42	-0.045 / -0.098	17

강력 추천 중 Top 20 밖의 변수: `past_mdd_5`, `log_value_20`, `foreign_hold`, `prog_nonarb_net_20`, `indiv_net_20`.
계산식은 `feature_candidates.csv`에 있다.

v1 대비 변화

- `idio_vol_60`: IR -1.80으로 여전히 강하다. 다만 이번에는 `gk_5`와 같은 묶음으로 분류돼 대표가 아니게 됐고, 그래서 '검토'가 됐다.
- `vol_ratio_20_60`: 월별 부호 일치율이 78%로 기준(80%)에 조금 못 미쳐 '검토'가 됐다. 변동성 통제 IR은 +0.64로 새로운 정보가 많다.
- 새로 강력 추천이 된 변수: `turnover_20` (v2 신규), `n_down3_60`

해석

- 변동성이 핵심이다.

- 1 ~ 3위와 5위는 모두 변동성 계열이다. 이들은 `idio_vol_60`, `vol_20` 등과 횡단면 상관이 약 0.7 이상이라, 모델에는 1 ~ 2개만 넣는 것을 권한다.
- 저가 기준 타깃에는 장중 변동폭이 들어 있어서, 고가·저가 기반 변수의 IC가 어느 정도 부풀려져 있다.
- **변동성을 통제한 뒤에도 남는 정보**(변동성 통제 $|IR| \geq 0.3$):
 - 가격 위치: `dist_low_60`, `pos_20`
 - 왜도: `skew_60`, `skew_20`
 - 과거 낙폭: `past_mdd_60`, `downside_ratio_20`, `n_down3_60`
 - 회전율: `turnover_20`
 - 신용잔고율: `margin_rate`
 - 연기금 순매수: `pension_net_5/20`
 - 변동성 변화: `vol_ratio_20_60`
 - 시가총액(`log_mcap`)은 단독으로는 약하지만(IR -0.04) 변동성 통제 IR이 +0.25다. 같은 변동성이면 대형주가 덜 빠진다.
- **변동성의 대리변수일 가능성이 큰 것:**
 - `lend_days_20` (IR 1.12 → 통제 후 0.22), `short_share_20` (0.64 → 0.07), `min_intra_drop_20` (1.33 → 0.12)
- **U자 관계:** 수익률·모멘텀 계열(`ret_5/20/60`, `ma_gap_*`)은 '검토' 등급이다. 많이 오른 종목과 많이 내린 종목이 모두 위험하다. 선형 모델에는 절댓값이나 제곱항이 필요하다.

시장 변수(날짜 공통)

- **강력 추천은 없다.** 겹치지 않는 표본이 108일뿐이라 근거가 약하다.
- 검토 등급 5개: `cs_dispersion_1` (p -0.22, p 0.02), `mkt_ret_20` (-0.19), `mkt_institution_net_20` (-0.18), `mkt_ret_60` (-0.18), `breadth_adv_5` (+0.15). 대부분 후반부(2026년 상반기)가 관계를 주도한다.

세 관점 비교

- 풀링 상관과 횡단면 IC의 부호가 다른 종목 변수는 4개(`excess_ret_5`, `ind_ret_5`, `prog_arb_net_20`, `short_share_1`)다.
- 시장 대비 초과수익률은 횡단면에서 음(-0.07)이지만, 날짜 평균끼리는 양(+0.14)이라 풀링하면 상쇄된다.
- **강건성:** v1 타깃, 늦은 갱신 행 제외, 공매도 재개 이후만, 2026년 상반기 제외 조건에서 부호가 뒤집힌 변수가 없다. 전·후반 IC 상관은 0.94다.




그림 5. Top 20 변수의 IC IR과 변동성 통제 후 IC IR

분위별 평균 초과 MDD_5 (같은 날 평균 대비) — |IC IR| 상위 12개




그림 6. 분위별 초과 MDD_5 (|IC IR| 상위 12개)




그림 7. 전·후반 IC 비교




그림 8. 시장 변수와 날짜별 평균 MDD_5의 시계열 상관

5. 누수 위험 요소

위험	내용	대응
타깃 함수	src/target.py 는 미래 가격을 쓴다	타깃 전용. 변수 코드에서 타깃 함수를 부르지 않는다(flag_low_spikes, clean_low 는 같은 날 값만 쓴다)
현재값 컬럼	stocks.shares_outstanding, stocks.status 는 수집 시점 값이다	쓰지 않는다. 회전율·시가총액은 KRX 일봉의 날짜별 상장주식수로 만들었다
업종	stocks.industry 는 현재값이다	업종은 거의 바뀌지 않으므로 정적 속성으로 쓴다(가정)
소급 조정 가격	수정주가가 수집 시점 기준으로 조정돼 가격 수준에 미래의 기업 이벤트가 반영돼 있다	비율 변수만 쓴다. 시가총액은 원주가(raw_close)로 계산했다
수급 공표 시점	t일 장 마감 후 공표분을 t일 변수로 쓴다(t+1일 장 시작 전 예측이라는 전제)	원천 갱신 시각이 t+1일 09:00 이후인 행에 late_update_20 플래그를 단다. 프로그램 매매와 기관 세부는 갱신 시각이 없어 확인할 수 없다
사후 재갱신	대차 2024-01 ~ 07 전체가 2024-08-08에 재갱신됐다	대차 변수는 2024-08 이후 표본으로 확인했고, 결론이 같았다
구성종목 소급 수집	스냅샷 34개가 모두 2026-09-16에 한 번에 수집됐다	편입·편출 시점은 공개 규칙과 대체로 맞는다. 월 단위 지연은 플래그로 남긴다
엠바고	학습 구간 마지막 5거래일의 타깃 구간이 검증 구간과 겹친다	타깃을 비워 두었고, 학습에서 제외한다
전체 기간 정규화	없음	롤링과 날짜별 순위만 썼다
검증	데이터 절단 테스트: 2025-06-30 이후를 지우고 다시 계산했을 때 변수 232개 × 72,461행이 전체 계산과 완전히 같았다	05_features.ipynb 2절

6. 모델링 시 주의점

- 시장 요인과 종목 요인을 나눠 평가한다.** 분산의 40%가 날짜 공통이다. 횡단면 성능은 날짜별 IC로, 시장 수준 예측은 날짜 평균 MDD의 오차로 따로 본다.
- 국면 변화에 대비한다.**
 - 2026년 상반기(전쟁 충격)는 $\leq -10\%$ 비율이 19.5%로 평소의 2 ~ 4배다.
 - 검증 구간이 이 국면 직후라서, 학습 구간 평균 수준을 그대로 예측하면 크게 틀릴 수 있다.
 - 시간 가중이나 롤링 재학습, 시장 수준 보정을 검토한다.
- 겹치는 타깃을 고려한다.** 인접 표본은 타깃 구간을 4일 공유한다. 교차검증은 날짜 블록 단위로 나누고, 블록 사이에 5거래일 간격을 둔다(purge/embargo). 유의성은 겹치지 않는 표본으로 본다.
- 변동성 계열의 중복을 정리한다.** 대표 1 ~ 2개만 쓰거나 규제(regularization)를 건다.
- 비선형성을 처리한다.** 수익률·모멘텀은 U자, 연기금·프로그램·개인 순매수 일부는 역U자다. 트리 모델이나 |값|·제곱항을 쓴다.
- 꼬리 위험을 따로 점검한다.** 타깃 분포의 왼쪽 꼬리가 두껍다(왜도 -1.7, 초과 첨도 4.9). 평균 오차 외에 하위 10% 구간의 순위 성능과 보정을 따로 본다.
- 수급 변수의 분모 기준을 유지한다.** 운영 단계에서도 투자자별·기관 매매는 통합 거래량으로, 공매도·프로그램 매매는 KRX 거래량으로 나눈다. 데이터 공급처가 바뀌면 기준부터 다시 확인한다.
- 공매도 변수는 체제 구분이 필요하다.** 2025-03-31 이전 값은 금지 기간이라 성격이 다르다.
- 거래정지 처리를 운영에도 적용한다.** 학습에서는 정지 관련 쌍을 뺐다. 운영에서 t일에 정지 중인 종목은 예측 대상에서 빼거나 따로 표시한다.

7. 한계와 남은 작업

- 추천 등급 기준은 분석자가 정한 경험적 기준이다. 06_relation.ipynb 7절에서 조정할 수 있다.
- 업종 변수는 현재 업종 분류를 과거에도 쓴 것이다.
- 시장 변수 평가는 108개 비중첩 날짜에 기반하므로 통계적 검정력이 낮다.
- KOSPI200 지수, 구성종목 변경 효력일, 거래정지·관리종목 지정 이력은 아직 없다(받으면 2절 4·8번이 개선된다).
- 다음 단계:** 모델링 — 최종 변수 세트 확정, 날짜 블록 교차검증 설계, 베이스라인(gk_5 단독 등), 모델 비교, 검증 구간 1회 평가.

부록: 산출물

파일	내용
outputs/data_dictionary.md	스키마, 사용 가능 여부, 공표 시차, 결정 사항
outputs/feature_candidates.csv	변수 133개: 계열, 계산식, 필요 과거 기간, 평균 IC, IC IR, 안정성, 추천 등급, 비교
outputs/notebooks/01_schema ~ 07_summary.ipynb, 03b_krx_validation.ipynb	Step 0 ~ 6, KRX 데이터 검증(03은 v1 기준 일봉의 품질 점검 기록)
outputs/figures/	그림
outputs/archive_v1/	v1(기존 DB 일봉 기준) 리포트, PDF, 변수 평가표
src/	db.py, data.py, universe.py, target.py, features.py, evaluate.py, plotting.py, report_pdf.py
data/cache/	Parquet 캐시(유니버스, 타겟, 변수, 평가 결과. *_v1 은 v1 결과)